

2026.6.5

语音信号处理期末 PROJECT汇报

声线克隆及语音匿名化

成员：张洪源 安文博 方一州 胡伟毅

遗憾

哎, 大学来做项目,
怎么感觉总是
跟男生合作啊?

是啊, 感觉好可惜,
从来没有和女生
做过项目……

KAI

REN

灵感

女声
…?

等等!
我想卷, 到了!
“女生”不就是
“女声”吗?

决定

所以! 我们要
实现“女声”!
我们决定做一个
变声器!

能把男声变成
女声, 女声变成
男声!

呲!

变声器
V1.0

成果

大家好!
我是“女声”
版本哦~❤️

项目预演
PRE

这就是我们的成果!
男声女声自由切换
变声器!

Tada! ✨

Aha ✨

OUR CONTENTS

01. 基础部分：WORLD单音频变声

02. 声线克隆：FreeVC (Coqui TTS)

03. 声线克隆：OpenVoice


04. 声线克隆拓展：语音匿名化

05. 总结与展示

01. 基础部分：WORLD单音频变声

WORLD声码器

WORLD声码器三层特征解耦



技术原理

- 将语音信号分解为**F0基频**、**频谱包络**、**非周期成分**（气声、摩擦音、清音等细节）三个独立参数
- 实现对**音高**与**共振峰**的独立操作，互不干扰



技术优势

- **可解释性强**：参数物理意义明确，便于理解调试；
稳定性高：算法成熟可靠
- **适合基础变声**，是实现声码器技术的首选方案

F0基频

音高控制

独立操控音调高低

频谱包络

音色塑造

决定语音音色特质

非周期成分

清浊分离

区分清音与浊音

1.先判断这段语音更像男声还是女声

提取完 F0 后先统计有效基频的中位数：

- 低于 165Hz → 判作男声 | 高于阈值 → 判作女声

这里用中位数而不是平均值，是因为：

- 中位数对个别异常帧更稳
- 更适合真实语音里有停顿、爆破音、局部跳变的情况

设计思想：先根据原始说话人的整体音高分布，自动估计当前音色属于哪一类，再决定往哪个方向推。


2. 不是只改音高，而是“音高 + 音色”一起改

2.1 音高怎么改

原始基频乘上一个 pitch_ratio：

- 男声 → 抬高到更接近女性的音高区间
- 女声 → 反向压低
- $\text{modified_f0} = \text{f0} * \text{pitch_ratio}$

这一步只是在改“音高”，如果只做这一步，听感往往会像“变速”或“假声”。



2.2 音色怎么改

真正让它更像目标性别的是频谱包络的平移。

频率轴重映射：

- 先构造原频率轴 `old_freq_axis`，再按 `formant_ratio` 反向缩放频率位置，用 `np.interp()` 对每一帧的频谱做插值
这相当于把共振峰整体往高频或低频方向移动：
- 男变女 → 共振峰上移，女变男 → 共振峰下移


3. 最后不是硬替换，而是混合回原声

合成时没有一刀切，而是用了一个强度参数 `strength`：


- `strength=1.0`：完全采用变声结果，`strength<1.0`：保留一部分原声
- 最后线性混合： $y = y_{\text{mod}} * \text{strength} + y_{\text{orig}} * (1.0 - \text{strength})$

这样做的好处是：

- 不会过度处理，可以在“自然度”和“男女化程度”之间调节，适合GUI调参



- 左边 __Before__ 是原始语音的 Mel 频谱，能量分布比较连续，低频和中频都有明显结构。
- 右边 __After__ 可以看到：
 - - 谐波条纹位置和密度发生变化；
 - - 高频和中频区域的能量分布与原图不同；
 - - 后半段有较多黑色区域，说明处理后部分弱能量或静音段被压低，能量更集中在有效语音片段上。




VAD 的全称是 __Voice Activity Detection__，也就是语音活动检测。

它的目的不是直接“美化声音”，而是先回答一个问题：这段音频里，哪些时间片段是人在说话，哪些片段只是背景噪声或静音？


在我们的系统里，VAD 放在 WORLD 变声之前。原因是：

- 1. F0 提取依赖清晰的人声周期结构，如果静音段或噪声段被误认为人声，可能会得到错误的基频轨迹。
- 2. 频谱包络容易被背景噪声污染，WORLD 的`cheaptrick()`会提取每一帧的频谱包络，如果噪声很多，音色轮廓就不干净。
- 3. 变声会放大原始问题
如果前面有底噪，后面再做音高变换和频谱重映射，噪声可能也会被一起处理，听起来更明显。

人声片段通常能量较高，而静音或背景噪声片段能量较低。因此我把整段音频切成很多短帧，逐帧计算能量，再根据自适应阈值判断每一帧是不是语音。



步骤 1：把连续音频切成短帧
步骤 2：计算每一帧的短时能量
这一部分是我们 VAD 的判断基础。
步骤 3：设计自适应阈值，而不是写死固定值
阈值 = 当前音频最大帧能量 × threshold_ratio
默认 `threshold\_ratio = 0.05`，也就是最大能量的 5%。
它会根据当前音频自动调整。
步骤 4：生成语音 / 噪声二值掩码
原始帧能量: [低, 低, 高, 高, 高, 低, 低] 1 表示这一帧是语音段
VAD mask: [0, 0, 1, 1, 1, 0, 0] 0 表示这一帧是噪声静音
步骤 5：加入简单 Hangover 平滑机制，避免语音断裂
真实语音里有些音素很短，比如清辅音、尾轻声，能量可能暂时低于阈值。如果直接为噪声，就会让语音听起来断断续续。
平滑前: [0, 1, 1, 0, 1, 1, 0]
平滑后: [0, 1, 1, 1, 1, 1, 0]
步骤 6：把帧级 mask 扩展回采样点级别
不是直接静音，而是软门限降噪
 $final_gain = mask_expanded * 0.9 + 0.1$
人声段保留 100%，非人声段保留 10%。



这个阶段的底层逻辑不是看整段音频响不响，而是看：在每个时间点、每个频率上，哪些成分更像噪声，哪些成分更像语音。

1. 为什么要转到频域？

时域信号只告诉我们“这一刻波形幅度是多少”。但噪声和人声经常是混在一起的，例如：你正在说话，同时背景里有风扇声。这时这一帧能量很高，VAD 会认为它是人声，于是整帧保留。可是风扇声也跟着被保留下来了。所以仅靠时域能量没法解决：

人声中夹杂的背景噪声

第二阶段就要进入频域。

频域会把声音拆成不同频率：


低频：轰鸣、空调、风声，中频：主要语音信息，高频：齿音、摩擦音、电流噪声

2. STFT：把声音切成“时间-频率图”

t = 第几个时间帧

f = 第几个频率 bin

$S[t, f]$ = 这个时间点这个频率上的能量



O2. 进阶部分：零样本音色变声

(1) 输入层

(2) 预处理层

(3) 特征提取层

- WORLD 路线：F0（基频）+ 频谱包络 + aperiodicity

- FreeVC/OpenVoice 路线：通常会用更深层的语音表示/embedding

4) 转换层

- FreeVC：偏语音转换

- OpenVoice：偏多说话人/提示式音色克隆


- WORLD：偏传统信号处理变声

5) 后处理 + 评估层

- 再做降噪/平滑

- 防爆音归一化

- 计算相似度指标



不能直接喂波形

原始波形是逐采样点的振幅，信息很多，但不利于模型学习：

- 维度太高
- 噪声太多
- 内容和音色混在一起
- 不同说话方式差异大，模型难收敛

常见的语音特征


短时傅里叶变换（STFT） / 频谱

Mel 频谱 / Mel-spectrogram

F0 / 基频

内容表示 / content representation

现代方法通常会把“说了什么”编码成一个更抽象的表示。 这类表示尽量弱化说话人特征，保留音素级内容。




零样本音色变声

不用为目标说话人专门训练一个模型，只用少量参考音频，就能让模型模仿这个人的声音特征。

- Step 1: 从目标参考音频提取 speaker embedding
比如目标人说一小段话，模型从中提取出目标音色的身份向量。
- Step 2: 从源音频提取内容表示
源音频说了什么，保留这个内容。
- Step 3: 提取或预测韵律
包括 F0、时长、停顿、能量起伏等。
- Step 4: 把目标 speaker embedding 注入生成器
生成器收到：源内容，目标音色，韵律信息

提预注生



FreeVC：深度语音转换思路

FreeVC 属于更现代的神经网络语音转换方法。

它学的是“数据分布”，
而不是手工规则。

它能够同时学习：

- 音色迁移
- 韵律调整
- 谐波结构重建
- 自然度修复

但缺点是：

- 更依赖模型和环境
- 运行成本高
- 对输入质量更敏感

1编码器-解码器结构

这是最经典的生成范式：

- 编码器提特征
- 解码器重建目标输出

2条件生成

不是无条件乱生成，而是“带条件生成”：


- 条件 1：内容
- 条件 2：目标 speaker embedding
- 条件 3：韵律/音高

3解耦表示

把内容和身份分开编码，避免说话人特征污染内容特征。

4隐空间映射

不同人的语音会被映射到一个更稳定的特征空间，在这里做风格替换比直接操作波形更稳定。



OpenVoice：零样本参考驱动风格迁移

OpenVoice 更强调“少量参考音频驱动的声音克隆”。

先从参考音频里抽取目标说话人的
style / speaker embedding
再把这个风格条件施加到输出上，
生成一个目标音色版本
零样本能力强
适合短参考音频
对“像目标谁”这件事比较直接

FreeVC 更偏结构性控制

常见控制点有：


- 目标 speaker embedding
- F0
- 韵律
- 转换强度

它更像是在控制生成路径里的几个重要模块。

OpenVoice 更偏风格性控制

常见控制点有：

- 参考音频质量
- tau（风格注入强度）
- 目标风格 embedding
- 自然化/保真度平衡



tau 参数

‘tau’ 可以理解成 “目标音色注入强度 / 变声力度控制参数”

情况 A：插值系数

模型在源风格和目标风格之间做插值：

$\text{style} = (1 - \text{tau}) * \text{source_style} + \text{tau} * \text{target_style}$

tau 越大，越往目标靠。

情况 B：条件强度

tau 控制目标 speaker embedding 在生成阶段的影响力。

- tau 小 → 目标条件“说话声”弱


- tau 大 → 目标条件“说话声”强

情况 C：解码温度/采样强度

有些实现里 tau 还会影响生成时的平滑程度或随机性。

- tau 小 → 输出更稳定、更保守

- tau 大 → 输出更激进、更像目标，但波动也更大



说话人相似度

先提取说话人 embedding

分别对：- 参考音频- 待评估音频

提取一个向量。

这个向量可以理解为“说话人身份指纹”。

再计算两个向量的距离或相似度

最常用的是 余弦相似度 cosine similarity。


公式是：

$$[\text{cosine}(a,b) = \frac{a \cdot b}{||a||, ||b||}]$$

含义：


- 1：方向完全一致，非常像
- 0：基本无关
- -1：方向完全相反

在语音里通常不会到 -1，更多是落在 0 到 1 的区间附近。




04.声线克隆拓展： 语音匿名化

核心算法框架： 基于FreeVC底座的三种方法变体（清晰度or内容保持）



04.声线克隆拓展： 语音匿名化

简单尝试、WebUI与波形分析



Speech Anonymization Recorder

录音后使用男声目标池全池搜索，生成 FreeVC baseline、Metric+clarity 和 PPG-tone 三种匿名化版本。

录音

建议录 3-10 秒。当前默认会评估 9 个男声参考，处理通常需要约 1-2 分钟。

开始录音

结束录音

匿名化处理

本次录音输出与即时评估

这里展示刚刚采集的录音、三种匿名化输出，以及针对本次录音计算的声纹相似度和 ASR 转写变化。

固定 benchmark 参考

这里是 `test.wav` 和 `绿色.m4a` 的报告基准测试，不代表刚刚网页录音的结果。

[▶ 展开固定测试集图表](#)

FreeVC baseline在音色迁移幅度上最大（蓝色），但声学变形也最明显；metric_clarity通过显式的声学指标优化（绿色），在包络保真度上优于FVC；PPG-tone通过PPG内容优先策略（青色），在包络形状上最为接近原信号。

04.声线克隆拓展： 语音匿名化

匿名效果：
VoicePrivacy以及
相关检测指标

指标	字段名	评估目标	说明
ASV-EER 	eer	Privacy	自动说话人验证系统的等错误率， 越高 说明越难被声纹识别
ASR-WER	asr_wer / wer	Utility	词错误率， 越低 说明语音内容保留越好
内容保留率	content_kept	实用性保留	从 WER 反推的内容保留比例
源相似度	source_similarity	隐私保护	匿名结果与源说话人的相似度，越低越好
相似度下降	similarity_drop	隐私保护	匿名前后相似度的下降幅度，越高越好


结果展示：
高保真度
低ASR-WER
低相似度

↓
高隐私的匿名
化处理

Lowest standard score 56.265 FreeVC optimized male
Best timbre removal 87.5% FreeVC optimized male
Lowest ASR WER 0.089 FreeVC optimized male
Best timbre index 0.886 FreeVC optimized male
Reference transcript 本次录音 语音信号出力,密名化,测试录音,speech anonymization recorder video。

Method	Source similarity	Standard score ↓	Similarity drop	ASR WER ↓	Content kept ↑	ASR hypothesis	Timbre index
FreeVC optimized male	0.125	56.265	87.5%	0.089	91.1%	语音信号处理,逆铃化,测试录音,Speech Anonymization Recorder Video。	0.886
Metric+clarity optimized male	0.146	57.275	85.4%	0.089	91.1%	语音信号处理,逆铃化,测试录音,speech anonymization recorder video。	0.871
PPG-tone optimized male	0.146	57.290	85.4%	0.089	91.1%	语音信号处理,逆铃化,测试录音,Speech Anonymization Recorder Video。	0.871

O5.总结与展示：完整系统结构



O5.总结与展示

完整语音处理系统本地UI展示



声学特征转换



声线克隆



语音匿名化

2026.6.5

THANK YOU

Thanks For Watching

小组成员：

张洪源	12310108	25%贡献比
安文博	12310403	25%贡献比
方一州	12310429	25%贡献比
胡伟毅	12313505	25%贡献比